

Generación automática de resúmenes médicos en lenguaje sencillo

M. Álvarez, D. Ayala, M. Hernández, R. Murcia

Facultad de Ingeniería - Maestría en Inteligencia Artificial

Universidad de los Andes, Bogotá, Colombia

ma.alvarezc1@uniandes.edu.co, de.ayala@uniandes.edu.co, ma.hernandezol@uniandes.edu.co, rs.murcia@uniandes.edu.co

Resumen—Este trabajo presenta un sistema para generar resúmenes biomédicos en lenguaje sencillo (PLS o *Plain Language Summary*) combinando un clasificador de estilo lingüístico y modelos generativos ajustados. Inspirado en la metodología CRISP-ML(Q), se tomaron datos de cuatro repositorios públicos, se entrenó un clasificador PLS/no-PLS con *Term Frequency-Inverse Document Frequency* (TF-IDF) + Regresión Logística y se realizó una comparación de modelos compactos con fine-tuning (Llama, Qwen, MedGemma, BioGPT) con fundacionales (>10B de parámetros) servidos vía API (GPT-5.1, Claude Sonnet-4.5, Gemini 2.5 Flash, Llama 3.1) bajo un protocolo uniforme para asegurar condiciones y comparaciones con las mismas condiciones. Se evaluaron con BERTScore (relevancia), AlignScore (factualidad) y métricas de legibilidad (Flesch-Kincaid, SMOG, Dale-Chall, Gunning Fog, entre otras), validando estilo con el clasificador. Se hizo uso de Gemini 2.5 Flash Lite para una revisión cualitativa de errores. Los resultados muestran que modelos afinados de bajo costo se aproximan a los fundacionales en PLS, aunque aún existe tensión entre factualidad y legibilidad, y se requiere trabajo futuro para mejorar accesibilidad sin perder información clínica.

Index Terms—Alfabetización en Salud, Procesamiento de Lenguaje Natural, Modelos de Lenguaje de Gran Escala (LLM), Resúmenes en Lenguaje Sencillo (PLS), Machine Learning Operations (MLOps).

I. INTRODUCCIÓN

La capacidad de acceder, comprender y utilizar información médica de manera adecuada, concepto conocido como alfabetización en salud es un factor decisivo para la adherencia terapéutica, la prevención de enfermedades y la toma de decisiones informadas [1]. Sin embargo, estudios internacionales como el European Health Literacy Survey reportan que alrededor del 50 % de los adultos presenta dificultades para interpretar textos biomédicos básicos [2], lo cual se correlaciona con mayor mortalidad evitable, incremento de hospitalizaciones y menor autonomía del paciente frente a su tratamiento.

Esta brecha se amplía en un contexto de sobreproducción científica, con literatura clínica que se duplica aproximadamente cada 73 días [3] y que, además, se redacta con un nivel terminológico equivalente a educación universitaria avanzada [4], mientras que la población general posee un nivel promedio de lectura equivalente a los grados 8 o 9 [5]. Esta distancia entre el lenguaje técnico y la capacidad lectora promedio dificulta el acceso equitativo a la información médica, especialmente para poblaciones vulnerables.

En respuesta a esta problemática, organismos internacionales han promovido la producción de resúmenes en PLS, con el

fin de comunicar resultados de ensayos clínicos a la ciudadanía [6]. No obstante, la elaboración manual de estos resúmenes continúa siendo costosa, dependiente de especialistas clínicos y con baja escalabilidad [7]. Paralelamente, los recientes avances en LLMs han mostrado potencial para simplificar textos biomédicos y generar versiones más comprensibles [8]. Sin embargo, esta oportunidad enfrenta limitaciones técnicas y éticas críticas: (i) riesgo de alucinaciones que distorsionan resultados clínicos [9], (ii) falta de mecanismos robustos para verificación factual automática, y (iii) dependencia económica de modelos cerrados de alto costo, como GPT-4o o Gemini, cuyas restricciones de acceso dificultan su adopción en hospitales, universidades y entidades públicas [10].

El presente trabajo aborda estos desafíos mediante el desarrollo de un sistema de generación de PLS conformado por dos componentes: un clasificador binario entrenado con representaciones dispersas y contextuales, y un módulo generativo basado en modelos decoder de bajo costo ($\leq 4B$ de parámetros). Inspirados en el paradigma CRISP-ML(Q) (Cross Industry Standard Process for Machine learning with Quality Assurance), se emplea un proceso reproducible de curación de datos biomédicos, ajuste fino de modelos open-source y evaluación multimétrica. Este último componente fue deliberado: la relevancia semántica se midió con BERTScore permitiendo la comparación entre múltiples modelos para la generación de PLS, la factualidad, con AlignScore; y la legibilidad, con seis métricas complementarias (Flesch-Kincaid, Coleman-Liau, SMOG, Dale-Chall, Gunning Fog y Flesch Reading Ease), debido a que una métrica aislada puede inducir conclusiones engañosas sobre accesibilidad lingüística.

Este trabajo investiga si modelos pequeños ajustados mediante *fine-tuning* (Llama, Qwen, MedGemma, BioGPT) pueden generar PLS biomédicos con calidad comparable a la de modelos fundacionales de gran escala (>10B) que no reciben entrenamiento adicional (GPT-5.1, Claude Sonnet-4.5, Gemini 2.5 Flash y Llama 3.1). Para garantizar la trazabilidad de estilo, el sistema incorpora un clasificador PLS/no-PLS basado en TF-IDF + Regresión Logística, encargado de verificar si las salidas generadas realmente respetan los principios de comunicación clara. Finalmente, se incorpora una evaluación cualitativa independiente utilizando Gemini 2.5 Flash Lite, permitiendo detectar errores lingüísticos y semánticos que no son capturables por métricas automáticas.

II. ESTADO DEL ARTE

La alfabetización en salud se reconoce como un determinante crítico de la equidad y de los resultados clínicos. Desde los trabajos pioneros de Nielsen-Bohman et al. (2004) [11] advirtió que la comunicación médica debía expresarse en un lenguaje claro y accesible para todos los públicos. Revisiones sistemáticas posteriores confirmaron que una baja alfabetización en salud se asocia con peor adherencia a tratamientos, más hospitalizaciones y mayores complicaciones clínicas [12]–[14]. Estas investigaciones también mostraron que los enfoques tradicionales como materiales impresos simplificados o programas de acompañamiento pueden mejorar la comprensión, pero presentan limitaciones de escalabilidad.

En la última década, el avance de la inteligencia artificial ha abierto nuevas posibilidades para superar esas limitaciones. Han surgido aplicaciones de modelos de lenguaje de gran escala (LLMs) orientadas a simplificar textos biomédicos y generar resúmenes en lenguaje sencillo. Un ejemplo es el proyecto Bridging the Gap in Health Literacy de Arias-Russi, Salazar-Lara y Manrique (2025) [15], que recopiló *datasets* biomédicos y mostró que modelos comerciales como GPT-4 producen resúmenes con alta legibilidad, aunque con riesgos de alucinaciones y pérdida de precisión factual. De manera complementaria, Devaraj et al. (2021) [16] evaluaron técnicas de *text simplification* basadas en aprendizaje profundo, concluyendo que mejoran la comprensión, pero exigen datos de calidad para evitar simplificaciones excesivas. Una revisión exhaustiva de Xie et al. (2023) [17] sobre *biomedical text summarization* destacó que, pese al potencial de los Large Language Models (LLM), persisten retos de factualidad, estandarización de evaluación y adaptación al lenguaje claro, mientras que Adams, Zucker y Elhadad (2023) [18] subrayan que métricas tradicionales como ROUGE o BERTScore no reflejan con precisión la fidelidad de los resúmenes clínicos.

Estos avances han impulsado el desarrollo de métricas específicas para evaluar legibilidad y fidelidad factual, aspectos cruciales para garantizar la calidad de los resúmenes generados. El BERTScore [19] mide la similitud semántica entre el resumen generado y el texto de referencia mediante *embeddings* contextuales, mostrando mejor correlación con la evaluación humana que las métricas basadas en *n-grams*. El más reciente AlignScore [20] introduce una función de alineación unificada entrenada en tareas de inferencia y verificación de hechos, capaz de analizar contextos extensos dividiéndolos en fragmentos y evaluar la factualidad a nivel de oración. A estas se suma la clásica Flesch-Kincaid, que estima el nivel educativo necesario para comprender un texto, y las guías de *plain language* como el CDC Clear Writing Guide [21], que recomiendan frases cortas, voz activa y evitar jerga técnica para maximizar la comprensión.

La investigación sobre legibilidad tiene raíces más antiguas: Rudolf Flesch (1948) [22] propuso una fórmula basada en longitud de palabras y oraciones, y años más tarde Coleman y Liau (1975) [23] perfeccionaron el método al introducir la técnica *cloze*, hoy ampliamente usada en evaluación de modelos de lenguaje. Sin embargo, incluso con métricas sofisticadas, la generación de textos médicos por LLMs enfrenta desafíos.

Investigaciones aún más recientes confirman la importancia de equilibrar legibilidad, relevancia y fidelidad factual. Joseph et al. (2024) [24] proponen FactPICO, un *benchmark* que evalúa la precisión de los elementos PICO (población, intervención, comparador, resultados) y revela que los modelos grandes suelen sacrificar exactitud al simplificar. Ji et al. (2024) [25], con RAG-RLRC-LaySum, demuestran que integrar *retrieval-augmented generation* y control de legibilidad mejora la accesibilidad sin perder relevancia. Finalmente, Nguyen et al. (2025) [26] presentan Medalyze, que evidencia que modelos de escala moderada afinados pueden igualar o superar a modelos comerciales en métricas como ROUGE y BERTScore, con ventajas de eficiencia y costo.

En conjunto, la literatura relacionada a este proyecto muestra una evolución clara: desde el reconocimiento inicial de la necesidad de lenguaje claro en salud, pasando por los primeros intentos de simplificación automatizada, hasta las métricas modernas que permiten evaluar con rigor la legibilidad y la fidelidad de los resúmenes. Este recorrido justifica el proyecto propuesto, que busca comparar de manera sistemática modelos pequeños ajustados y grandes modelos comerciales en la generación de resúmenes biomédicos en lenguaje sencillo, aportando evidencia sobre el equilibrio entre calidad de la información, escalabilidad y costo computacional.

III. METODOLOGÍA

A. Diseño metodológico general: El proyecto se inspiró en CRISP-ML(Q), con ciclos iterativos de entendimiento del problema, preparación de datos, modelado, evaluación y despliegue, integrando controles de calidad desde el inicio. El objetivo fue mantener trazabilidad y reproducibilidad en todas las decisiones técnicas, a continuación, la aplicación de las 6 fases sugeridas de esta metodología:

Comprensión de negocios y datos: se definió la brecha entre texto técnico y PLS, el nivel lector objetivo (aproximadamente 8° grado) y las métricas clave para comparaciones y entendimiento del proyecto de forma cuantitativa.

Ingeniería de datos: curación de cuatro fuentes biomédicas públicas, integridad por medio de *hash*, filtrado de textos cortos, normalización ligera y partición estratificada.

Ingeniería de modelos: clasificador como compuerta de estilo PLS/no-PLS. Supervised Fine-Tuning (SFT) con QLoRA (Quantized Low-Rank Adaptation) en modelos menores a 4B de parámetros (cuantización 4 bits, adaptadores en atención) y protocolos de inferencia uniformes para modelos fundacionales vía API para comparación de resultados.

Garantía de calidad: evaluación multimétrica (BERTScore-F1, AlignScore, Flesch-Kincaid, SMOG, Dale-Chall, Gunning Fog) y validación cruzada con el clasificador, revisión cualitativa con Gemini 2.5 Flash Lite.

Despliegue: artefactos en contenedores (API FastAPI, front Angular/nginx, AlignScore), desplegando en la nube AWS usando ECR y orquestación con Docker Compose en EC2, con precondiciones y pruebas para un despliegue correcto.

Monitoreo y mantenimiento: estructura preparada para actualizar modelos/*checkpoints* y monitorear disponibilidad y métricas de salud de servicios (/health, smoke tests), además de ajustar parámetros y artefactos montados desplegados.

B. Datos y preparación: Se escaneó y analizó un corpus biomédico público (Cochrane PLS, Pfizer y ClinicalTrials.gov, ClinicalTrials), con un inventario inicial de 65,053 documentos en texto plano UTF-8. Tras la revisión de pares existentes No-PLS + PLS, se encontró que solo el 6 % (3,862) eran pares utilizables para la tarea de fine-tuning y el 10.9 % (7,076) no tenían par, el otro 83.1 % corresponde a fracciones de los textos completos. La distribución final se muestra a continuación:

- Entrenamiento: 3,276 ejemplos (84.8 %)
- Validación: 365 ejemplos (9.5 %)
- Prueba: 221 ejemplos (5.7 %)

No fue necesaria una duplicación ya que para los pares de texto armados, todos los documentos eran únicos. Además, se detectó un fuerte desbalance y heterogeneidad de longitud (*ClinicalTrials.gov* con colas >3,000 palabras), por lo cual se implementó una estrategia para el conteo de *tokens* a fijar en el SFT garantizando la no pérdida de información por truncamiento.

Cuadro I
FUENTES DE DATOS UTILIZADAS Y PROPORCIONES.

Fuente	Tipo	Notas de uso	% Datos usados
Cochrane PLS	Pares técnico→PLS	Pilar para SFT y evaluación.	98.3 %
Pfizer y Clinical Trials.gov	PLS y Técnico	Estilo homogéneo; comparación.	1.7 %

C. Modelos de Machine Learning y LLMs:

C1. Clasificador PLS/no PLS: El sistema incorpora un clasificador binario para distinguir textos biomédicos en lenguaje técnico de resúmenes PLS. Se usará como verificación previa a la generación automática para validación y prevenir generar un contenido resumido a un texto que ya es PLS. Para este clasificador se tuvieron en cuenta las siguientes opciones y condiciones de validación:

- **Representaciones dispersas:** Se construyó una matriz TF-IDF mixta: n-gramas de palabra (1–2) y de carácter (3–5). Sobre esta representación se entrenaron dos modelos supervisados: Regresión Logística (solver SAGA, C=2.0) y *Support Vector Machine* (SVM) lineal. El SVM se calibró con Platt para obtener probabilidades comparables.
- **Representaciones contextuales:** Se empleó DistilBERT para clasificación de secuencias con la arquitectura estándar de *Transformers*. El modelo se ajustó (*fine-tuning*) para la tarea de dos clases y se validó con el mismo protocolo que los enfoques dispersos.
- **Protocolo de validación:** Se realizó un particionamiento estratificado 85/9/6 por fuente y clase. El umbral de decisión se fijó maximizando F1 en validación y las métricas finales se reportan sobre test.

C2. Generación de PLS con SFT ($\leq 4B$): Se definieron cuatro arquitecturas candidatas para la fase de experimentación (SFT): Qwen 2.5-3B, Llama 3.2-1B, MedGemma 4B y BioGPT-Large. Estos modelos fueron elegidos para representar diferentes compromisos entre tamaño, especialización biomédica y capacidad multilingüe:

- **Qwen 2.5-3B (Alibaba):** Modelo de propósito general optimizado en chino e inglés, con arquitectura eficiente para tareas de compresión y sumarización. Se seleccionó por su bajo costo computacional y su capacidad demostrada en razonamiento factual bajo recursos, lo que permitió evaluar el efecto del *fine-tuning* en un modelo emergente pero compacto. Su inclusión también buscó contrastar el comportamiento de un modelo multilingüe en PLS biomédico.
- **Llama 3.2 -1B (Meta):** Arquitectura abierta, ligera y ampliamente usada como baseline de investigación. Aunque su tamaño es limitado, ha mostrado rendimiento competitivo en tareas de NLP clásicas tras SFT. Se incluyó como referencia mínima de capacidad, con el fin de cuantificar cuánto depende el desempeño PLS del tamaño del modelo vs. del proceso de entrenamiento supervisado.
- **MedGemma 4B (Google):** Modelo especializado en dominio biomédico derivado de Gemma, con pre-entrenamiento en textos clínicos, científicos y médicos. Se seleccionó como candidato de alto rendimiento dentro del rango $\leq 4B$, permitiendo medir el impacto del conocimiento biomédico previo frente a modelos generalistas de tamaño similar.
- **BioGPT Large – 1.5 B (Microsoft):** Modelo biomédico pre entrenado sobre literatura científica (PubMed), optimizado para comprensión y generación de texto clínico. Aunque es pequeño, su especialización lo convierte en un excelente comparador entre tamaño reducido y conocimiento de dominio. Se incluyó para evaluar si un modelo muy especializado puede competir con arquitecturas más grandes tras SFT.

Detalle de entrenamiento: Se implementó SFT y QLoRA para afinar los modelos $\leq 4B$ sobre pares técnicos→PLS. La cuantización nf4 y los adaptadores LoRA se aplicaron exclusivamente en las capas de atención, manteniendo el modelo base congelado, la optimización se realizó con `paged_adamw_8bit` y objetivo *cross-entropy*, asegurando eficiencia en VRAM y reproducibilidad (*stack* PEFT, Unsloth, TRL, Transformers).

Se usó un `max_seq_length = 4096` tras realizar un análisis de longitud de texto (*prompt* + técnico + *pls*) en el percentil 99. Lo anterior fue importante para no entrenar con textos incompletos.

Detalle de inferencia: Para garantizar comparabilidad entre los modelos evaluados, se definió un conjunto consistente de hiperparámetros de generación para todos los sistemas durante la etapa de inferencia. La configuración base incluyó: `top_p=0.9`, `temperature=0.3` y `top_k=50`.

Estos valores fueron seleccionados por su uso común en tareas de generación controlada y porque permiten un equilibrio adecuado entre diversidad y estabilidad estilística,

favoreciendo resúmenes más coherentes y con menor riesgo de alucinación. Cada modelo fue evaluado bajo este mismo esquema para asegurar condiciones justas de comparación.

C3. Modelos fundacionales (>10B) para comparación:

Para evaluar como los procesos SFT en modelos pequeños tiene un resultado adecuado para la tarea que se desea entrenar, se hicieron el análisis de 100 textos técnicos estratificados de toda la muestra disponible contra los siguiente modelos comerciales vía API:

- ChatGPT 5.1.
- Claude-sonnet-4-5- 20250929.
- Gemini 2.5 Flash Lite.
- Llama 3.1 8B Instruct.

Se aplicó el mismo protocolo de entrada/salida con las mismas métricas para garantizar paridad en el momento de comparación.

D. Análisis de prompts: La construcción del *prompt* se diseñó mediante un esquema de restricciones explícitas orientado a garantizar la consistencia en el idioma, la estructura y la longitud del resumen generado. Para mitigar la aparición de contenido en idiomas distintos al inglés –un comportamiento observado en modelos multilingües probabilísticos– se incorporó una cláusula imperativa de restricción de idioma ('English only'). Asimismo, se definieron parámetros de formato negativo para excluir encabezados, títulos o metadatos no deseados, asegurando que la salida fuera un único párrafo de texto continuo. Finalmente, en lugar de imponer límites rígidos de *tokens* que pudiesen truncar información clínica crítica, se optó por una instrucción de longitud basada en oraciones e ideas completas (máximo 500 palabras), buscando un equilibrio entre la capacidad de síntesis y la preservación de detalles esenciales como advertencias de seguridad y resultados numéricos.

E. Evaluación: La evaluación se dividió en dos grandes fases: cuantitativa y cualitativa.

E1. Fase cuantitativa: Se utilizaron tres tipos de métricas para la evaluación y comparación de modelos:

- **Relevancia semántica (Texto técnico vs Generado):** BertScore aprovechando su comparación de *embeddings*.
- **Factualidad (PLS Humano vs Generado):** Función de alineación AlignScore (NLI_SP) en entorno aislado para gestionar dependencias. Proporción de contradicciones NLI (1 – razón de contradicción con modelo BART-MNLI) y QA-Answerability (QG + AQ con modelo T5/DistilBERT). Estos tres métodos permitieron lograr una comprensión más holística de los PLS generados.
- **Legibilidad:** Para este tipo de métricas se usaron los umbrales de el cuadro II.

Las métricas de legibilidad para grado escolar buscan corresponder el PLS a un nivel de lectura accesible para la mayoría de los adultos, típico de un estudiante de 8° grado (US 8th grade [~13–14 años], comparable a educación secundaria baja [ISCED-2] en Europa).

Cuadro II
UMBRALES PARA MÉTRICAS DE LEGIBILIDAD EN PLS.

Métrica	Umbral	Tipo de Umbral
Flesch-Kincaid Grade Level (FKGL)	<8.0	Grado Escolar
Flesch Reading Ease (FRE)	≥60	Facilidad de Lectura (Puntos)
Gunning Fog Index	<8.0	Grado Escolar
SMOG Index	<8.0	Grado Escolar
Coleman-Liau Index (CLI)	<8.0	Grado Escolar

E2. Fase cualitativa: Se utilizó un modelo SOTA (State-of-the-Art), en este caso, Gemini 2.5 Flash para la evaluación de los PLS vs el texto técnico. La salida fue un archivo JSON con los campos booleanos descritos en el cuadro III.

Cuadro III
CRITERIOS DE EVALUACIÓN CUALITATIVA.

Métrica	Descripción
Legibilidad (8°)	¿Es fácil de leer para una persona con baja escolaridad (FKGL ≤ 8.0)?
Factualidad	¿Contiene los principales hallazgos y conclusiones del texto original?
Factualidad Completa	¿Contiene todos los hallazgos y conclusiones del texto original?
Alucinaciones	¿Presenta ideas que no están en el texto original?
Omisiones	¿Omite información importante del texto original?
Jerga Excesiva	¿Hace uso de una jerga técnica difícil de entender?
Objetividad	¿Mantiene un tono objetivo?
Err. Gramática	¿Tiene errores gramaticales?
Err. Ortografía	¿Tiene errores ortográficos?
Coherencia	¿Es coherente a lo largo de todas las ideas del texto?
Repeticiones	¿Tiene palabras, frases o ideas repetidas?
Frases Cortadas	¿Tiene palabras, frases o ideas incompletas?

Finalmente, se analizó manualmente la salida de esta evaluación para confirmar o corregir valores.

F. Despliegue: Se adoptó un enfoque MLOps (*Machine Learning Operations*) sobre AWS (*Amazon Web Services*) para automatizar y trazar el ciclo completo: artefactos contenedORIZADOS se versionan y publican en ECR (*Elastic Container Registry*), la infraestructura se define como código haciendo uso de Terraform para aprovisionar EC2 (*Elastic Compute Cloud*) y redes, por otro lado Docker Compose orquesta los servicios de forma reproducible con variables y plantillas parametrizables. La integración y entrega continua aseguran empaquetados consistentes, *checks* de salud y *smoke tests*

actúan como *guardrails*. Este esquema, pensado para la nube, minimiza costos operativos y acelera iteraciones de datos y modelos, haciendo viable el despliegue productivo del PLS.

G. Consideraciones Éticas y de Seguridad: El desarrollo del sistema se rige por principios de IA Responsable transversales a todas las fases del proyecto. En primer lugar, se garantizó la privacidad de los datos mediante el uso exclusivo de repositorios de acceso abierto y anonimizados (Cochrane, PubMed), eliminando cualquier riesgo de exposición de información sensible de pacientes reales. En segundo lugar, se abordó la seguridad clínica priorizando la factualidad sobre la fluidez; dado el riesgo inherente de alucinaciones en los LLMs, el sistema se diseñó bajo el paradigma de *human-in-the-loop*, concibiéndolo como una herramienta de asistencia para la redacción y no como un sustituto del juicio médico profesional. Finalmente, el proyecto se alineó con principios de IA Sostenible (*Green AI*), al demostrar que modelos compactos ajustados (SLMs) pueden competir con arquitecturas masivas, reduciendo significativamente la huella de carbono computacional y democratizando el acceso a tecnología biomédica en entornos con recursos limitados.

IV. RESULTADOS Y ANÁLISIS

Este capítulo presenta los resultados experimentales obtenidos durante el desarrollo del sistema de generación de resúmenes biomédicos en lenguaje sencillo. Los hallazgos se organizan de acuerdo con las actividades del proyecto: clasificación automática de lenguaje técnico y sencillo, generación y evaluación de resúmenes con modelos open-source ($\leq 4B$), comparación con modelos comerciales ($>10B$), análisis multimétrico cuantitativo y análisis cualitativo.

A. Clasificador PLS/no-PLS: Para contrastar los enfoques de clasificación PLS/no-PLS se estimó su desempeño en validación estratificada, reportando métricas estándar (F1-macro, *accuracy*, precisión y *recall*) para LogReg y SVM sobre TF-IDF y para el modelo contextual DistilBERT. El cuadro IV resume estos indicadores, permitiendo comparar capacidad predictiva y estabilidad entre las variantes dispersas y la alternativa contextual.

Cuadro IV
COMPARATIVA DE RENDIMIENTO DE LOS MODELOS DE CLASIFICACIÓN.

	TF-IDF + LogReg	TF-IDF + SVM	DistilBERT
Rendimiento			
CV F1-macro	0.9983	0.9993	—
Val Accuracy	0.9985	0.9992	0.9989
Val F1-macro	0.9988	0.9991	0.9991
Val Precisión	0.9979	0.9999	0.9997
Val Recall	0.9989	0.9991	0.9991
Val ROC-AUC	0.9999	0.9999	0.9999
Test Accuracy	0.9971	0.9974	0.9984
Test F1-macro	0.9968	0.9971	0.9983
Operacional			
Complejidad	Baja	Media	Alta
Tiempo de entrenamiento	< 3 min	5-6 min	≈ 35 min (GPU)
Cómpu	CPU	Light GPU	GPU (CUDA/MPS)
Interpretabilidad	Alta	Media	Baja
Escalabilidad	Muy Alta	Alta	Media-Baja

Los resultados de la clasificación PLS vs. no-PLS demostraron un rendimiento sobresaliente en todos los enfoques, con métricas de F1-macro > 0.99 y ROC-AUC ≈ 1.0 , indicando una capacidad de discriminación casi perfecta. Dada la marginal diferencia en el rendimiento predictivo, la decisión técnica se basó en criterios operativos como la interpretabilidad y la eficiencia computacional, favoreciendo al modelo de **TF-IDF + Regresión Logística** como el clasificador principal de la solución.

B. SFT Modelos $\leq 4B$: A continuación, se encuentra un cuadro comparativo con los resultados de los 4 modelos a los que fueron sometidos a un proceso SFT para la generación de PLS:

Cuadro V
MÉTRICAS DE 5 LLMs CON SFT PARA PLS.

Métrica	Meta	Qwen2.5-3B	Llama-3.2-1B	Med Gemma-4B	BioGPT-Large-1.5B
Relevancia Semántica					
BERTScore-F1	≥ 0.86	0.870	0.828	0.752	0.780
BERTScore-Precisión	≥ 0.8	0.821	0.853	0.727	0.775
BERTScore-Recall	≥ 0.8	0.845	0.840	0.739	0.777
Legibilidad					
Flesch-Kincaid Grade	< 8.0	9.973	13.10	8.40	13.23
Flesch Reading Ease	≥ 60	52.80	29.09	36.62	32.58

Basados en los resultados obtenidos en la evaluación inicial, Qwen 2.5 (3B) y MedGemma (4B) fueron seleccionados como los modelos candidatos para mejorar los procesos de *fine-tuning* con una mejora continua de sus *prompts*. A partir de esta selección, se procedió a analizar la calidad cualitativa de los textos generados por ambos modelos, evidenciando que aún no se alcanzaba completamente el objetivo de producir resúmenes en lenguaje sencillo, libres de repeticiones y con factualidad adecuada.

En consecuencia, el análisis final se estructuró en dos dimensiones complementarias:

Evaluación cuantitativa, basada en métricas estandarizadas: BERTScore para relevancia semántica, AlignScore para factualidad lógica, y comparación con modelos comerciales de mayor tamaño.

Evaluación cualitativa, centrada en el análisis lingüístico de los textos, considerando errores de redacción, omisiones de resultados clínicos relevantes, presencia de jergas no explicadas, simplificación excesiva y posibles riesgos comunicativos para el lector no especializado.

C. Implementación del prompt: El análisis experimental sobre el diseño de las instrucciones permitió consolidar una arquitectura de *prompt* único. A diferencia de enfoques previos

que requerían instrucciones diferenciadas por tipo de documento, los resultados confirmaron que los modelos actuales poseen la robustez y capacidad de generalización necesarias para procesar la heterogeneidad del texto clínico con un mismo *set* de reglas unificado. La configuración final de este *prompt* respondió a tres hallazgos críticos observados durante las iteraciones de prueba:

Control de Consistencia y Formato: Se detectó que la ambigüedad en las instrucciones provocaba la aparición de caracteres en idiomas no solicitados (comportamiento acentuado en Qwen) y la inclusión de metadatos o títulos innecesarios. Esto se mitigó eficazmente al incorporar cláusulas imperativas de restricción de idioma ('English only') y al exigir explícitamente la generación de un párrafo único y plano.

Equilibrio entre Síntesis y Factualidad: Las pruebas revelaron que los límites rígidos basados en conteo de palabras forzaban al modelo a omitir datos numéricos y advertencias de seguridad, afectando negativamente el *AlignScore*. Se determinó que la métrica óptima de control no era la longitud en palabras, sino un límite estructural de máximo 500 palabras con ideas completas, lo cual logró preservar la densidad informativa sin sacrificar la brevedad.

Operacionalización de la Legibilidad: Dado que los modelos de lenguaje no tienen la capacidad de calcular fórmulas matemáticas (como FKGL o SMOG) durante la inferencia, se demostró que solicitar puntajes métricos específicos resultaba ineficaz. En su lugar, se validó que la instrucción conceptual de 'nivel de comprensión de lectura de 8° grado' guiaba mejor la simplificación léxica, reservando el uso de las escalas numéricas estrictas (FKGL, SMOG, FRE) exclusivamente para la validación cuantitativa posterior.

D. Evaluación Cuantitativa:

Cuadro VI

MÉTRICAS DE MODELOS AJUSTADOS (SFT) VS. REFERENCIA HUMANA.

Métrica	Meta	PLS Ref.	MedGemma	Qwen
BERTScore - F1	≥0.86	—	0.85	0.83
AlignScore (NLI_SP)	≥0.80	—	0.49	0.25
Factualidad (1 - Contradiction Ratio)	≥0.90	—	0.99	0.97
Factualidad (QA Answerability)	≥0.80	—	0.13	0.08
Flesch-Kincaid Grade	<8.0	13.96	11.39	12.80
Flesch Reading Ease	≥60	34.25	46.29	31.08
Gunning Fog Index	<8.0	16.92	13.68	15.59
SMOG Index	<8.0	15.46	13.13	14.23
Coleman-Liau Index	≤8.0	14.12	12.68	15.62

D1. Análisis de modelos con fine tuning: La evaluación inicial de los cuatro modelos candidatos tras el proceso de ajuste fino (SFT) reveló una tensión evidente entre la fluidez del texto y la precisión de la información. Como se observa en el cuadro VI, Qwen 2.5 obtuvo el BERTScore más alto (0.83), lo que indica que es capaz de generar textos gramaticalmente muy similares a los escritos por humanos. Sin embargo, esta fluidez resultó engañosa: su AlignScore fue preocupantemente bajo (0.25). Dado que en este proyecto la métrica de factualidad compara la salida del modelo contra el resumen humano (PLS) y no contra el texto técnico, este puntaje bajo sugiere que Qwen tiende a incluir información que el humano decidió omitir, o a formular conceptos de una manera que se desvía del

estándar de simplificación validado, 'alucinando' contenido que no estaba en la referencia simplificada.

Por el contrario, MedGemma demostró ser el modelo más equilibrado y seguro para el dominio clínico. Logró el AlignScore más alto del grupo (0.49), duplicando prácticamente la capacidad de Qwen para mantenerse fiel al resumen de referencia. Además, en términos de accesibilidad, MedGemma consiguió el mejor puntaje de legibilidad (FKG 11.39). Aunque este nivel sigue siendo superior al objetivo ideal de 8° grado (escuela secundaria), es notablemente más accesible que Llama 3.2, cuyo grado de dificultad (13.10) requiere un nivel de lectura universitario, haciéndolo inadecuado para pacientes con baja alfabetización en salud.

Es importante notar que ningún modelo ajustado logró romper la barrera del grado 10 de complejidad. Esto probablemente se debe a que, incluso con el entrenamiento, los modelos conservan terminología médica técnica (palabras largas) que penaliza las fórmulas de legibilidad, sugiriendo que el ajuste fino (SFT) por sí solo no es suficiente para forzar una 'traducción' completa de términos complejos a lenguaje coloquial.

D2. Análisis de modelos Comerciales: Para contextualizar el desempeño de los modelos luego de SFT, se compararon contra líderes de la industria. Contrario a lo que se podría pensar, el análisis de datos sugiere que ser más grande no implica simplificar mejor.

Cuadro VII

MÉTRICAS DE MODELOS FUNDACIONALES VS. REFERENCIA HUMANA.

Métrica	Meta	PLS Ref.	ChatGPT	Claude	Gemini	Llama
BERTScore - F1	≥0.86	—	0.86	0.86	0.86	0.86
AlignScore (NLI_SP)	≥0.80	—	0.40	0.41	0.47	0.49
Factualidad (1-Contradiction)	≥0.90	—	0.99	0.99	1.00	1.00
Factualidad (QA Answer.)	≥0.80	—	0.15	0.14	0.17	0.15
Flesch-Kincaid Grade	≤8.0	13.9	10.14	11.22	10.33	11.03
Flesch Reading Ease	≥60	34.2	53.15	48.33	52.20	49.23
Gunning Fog Index	≤8.0	16.9	12.27	13.18	12.37	13.37
SMOG Index	≤8.0	15.4	12.21	12.98	12.33	13.07
Coleman-Liau Index	≤8.0	14.1	11.85	13.16	12.08	12.27

Si bien todos los modelos comerciales mostraron una buena fluidez (BERTScores superiores a 0.86), sus métricas de factualidad (AlignScore) oscilaron entre 0.40 y 0.49 (Cuadro VII). Esto es un hallazgo crítico para el proyecto: un modelo masivo y costoso como GPT-4o obtiene un AlignScore de 0.40, un puntaje inferior a nuestro modelo pequeño MedGemma (0.49). Esto implica que, para la tarea específica de replicar resúmenes humanos simplificados, los modelos comerciales no ofrecen una ventaja significativa en precisión factual sobre un modelo pequeño bien entrenado.

En cuanto a la legibilidad, los modelos comerciales también fallaron en alcanzar el nivel de escuela secundaria, estabilizándose un grado de dificultad de 10 a 11. Esto refuerza la hipótesis de que la simplificación médica es un problema

estructural que requiere estrategias más allá de la simple instrucción (*prompting*) a modelos gigantes; requiere un control de vocabulario que ni siquiera los modelos más grandes aplican de forma nativa.

Al contrastar directamente al mejor modelo ajustado (MedGemma) contra los mejores comerciales, los resultados validan la viabilidad técnica y económica de nuestra propuesta.

Rendimiento vs. Costo: MedGemma alcanza mayor fidelidad factual (AlignScore 0.49) que GPT-4o (0.40), pero lo hace con una arquitectura más ligera, lo que permite su implementación local sin depender de APIs de pago ni comprometer la privacidad de los datos médicos.

Legibilidad: Sorprendentemente, MedGemma obtuvo un índice de legibilidad (11.39) ligeramente mejor que los modelos comerciales. Esto sugiere que el entrenamiento específico con un *dataset* de PLS ayudó al modelo a adoptar un estilo más directo y claro que el de los asistentes generales.

E. Evaluación Cualitativa: A continuación, se muestran los resultados de la evaluación cualitativa realizada sobre 100 textos generados por los modelos ajustados MedGemma y Qwen y los PLS de referencia creados por humanos (Cuadro VIII).

Cuadro VIII
REFERENCIA HUMANA VS. MODELOS FINE-TUNED (MEDGEMMA Y QWEN)

Métrica	PLS Ref.	MedGemma	Qwen
Legibilidad (8°)	0 %	47 %	0 %
Factualidad	100 %	100 %	83 %
Factualidad Completa	75 %	73 %	10 %
Alucinaciones	0 %	0 %	13 %
Omisiones	27 %	28 %	90 %
Jerga Excesiva	39 %	10 %	61 %
Objetividad	100 %	100 %	100 %
Err. Gramática	0 %	0 %	40 %
Err. Ortografía	0 %	0 %	66 %
Coherencia	100 %	97 %	77 %
Repeticiones	4 %	16 %	36 %
Frases Cortadas	0 %	4 %	49 %

Como se puede observar, MedGemma aprendió un 47 % de las veces a simplificar la legibilidad del texto para alcanzar la meta de 8°, frente a un 0 % en los PLS de referencia y Qwen. Además mantuvo un 100 % en consistencia factual (parcial), un 0 % de alucinaciones (igualando al texto humano), 0 % en errores gramaticales y ortográficos, 16 % en repetición de frases, 4 % en frases cortadas y un 28 % en omisión de información importante, muy similar al 27 % humano y lejos del 90 % de Qwen. Finalmente, MedGemma alcanza una completitud en factualidad de 73 % frente al 75 % humano, lo que significa que el modelo es capaz de mantener en el texto final las principales conclusiones o hallazgos del texto médico.

Por otro lado, el modelo Qwen presenta un 40 % de errores gramaticales y un 66 % en ortográficos frente a un 0 % para el humano y MedGemma. También fue el modelo con menor completitud factual (10 %), con mayor número de frases cortadas (49 %) y repeticiones (36 %), mayor número de alucinaciones (13 %) y jerga técnica excesiva (61 %).

Lo anterior demuestra que MedGemma es una solución viable para la generación de PLS médicos, llegando a igualar a los PLS humanos y a superarlos en la meta de legibilidad para 8°.

En el cuadro (Cuadro IX) se muestran los resultados del mismo análisis para los modelos SOTA. Al observar los resultados en conjunto, lo primero que llama la atención es que todos los modelos comerciales se comportaron de forma segura, con un porcentaje de alucinaciones del 0 % y 100 % de consistencia factual. Gemini logra el mayor equilibrio entre legibilidad (57 %) y completitud factual (99 %). Llama es una alternativa robusta de pesos abiertos, con 50 % de legibilidad y sin frases cortadas. ChatGPT y Claude, aunque factualmente correctos, tienden a generar textos con frases cortadas (52 % y 37 % respectivamente), lo que reduce su utilidad sin post-procesamiento.

Cuadro IX
REFERENCIA HUMANA VS. MODELOS COMERCIALES (SOTA).

Métrica	PLS Ref.	Gemini	ChatGPT	Llama	Claude
Legibilidad (8°)	0 %	57 %	22 %	50 %	42 %
Factualidad	100 %	100 %	100 %	100 %	100 %
Factualidad Completa	75 %	99 %	81 %	80 %	87 %
Alucinación	0 %	0 %	0 %	0 %	0 %
Omisiones	27 %	1 %	26 %	21 %	15 %
Jerga Excesiva	39 %	3 %	9 %	7 %	4 %
Objetividad	100 %	100 %	100 %	100 %	100 %
Err. Gramática	0 %	0 %	0 %	0 %	1 %
Err. Ortografía	0 %	0 %	0 %	0 %	1 %
Coherencia	100 %	100 %	100 %	100 %	100 %
Repeticiones	4 %	3 %	0 %	8 %	1 %
Frases Cortadas	0 %	0 %	52 %	0 %	37 %

Gemini logra el mayor equilibrio entre legibilidad y completitud factual, alcanzando un 57 % en legibilidad para la meta de 8°, lo que supera el 0 % y 50 % para PLS humanos y de Llama respectivamente. Además, alcanzó una completitud factual del 99 %, superando ampliamente a la referencia humana, que se quedó en tan solo 75 %. Sumado a todo esto, el uso de jerga fue mínimo, con apenas un 3 %, y no presentó frases cortadas.

Aquí es importante analizar el comportamiento de los modelos de ChatGPT y Claude. Aunque ambos mantienen una calidad factual perfecta, las métricas muestran que muchos de sus resúmenes tienen frases cortadas. En el caso de ChatGPT se observó un 52 %, y para Claude un 37 %, lo que sugiere que los textos generados excedieron el límite de *tokens* o se volvieron demasiado extensos. Este tipo de cortes reduce de forma significativa la legibilidad y la utilidad de los resúmenes, ya que requieren *post-procesamiento* o edición humana para ser consumidos adecuadamente.

Por último, el modelo Llama aparece como una alternativa bastante sólida, sobre todo si se busca trabajar con modelos de pesos abiertos. Se puede observar un 50 % de legibilidad y, al igual que Gemini, no presenta frases incompletas. Aunque no alcanza el mismo nivel de Gemini en completitud factual y legibilidad, se posiciona como una opción muy robusta cuando se valora poder adaptar el modelo, tener más control técnico sobre él o integrarlo en entornos donde los pesos abiertos son una ventaja importante.

Aunque este análisis se realizó usando Gemini 2.5 Flash (por velocidad en la respuesta de la API), la revisión manual

confirmó los valores aquí presentados.

F. Evolución del Loss durante el fine tuning de MedGemma con QLora: En la figura 1, los valores de training loss y validation loss muestran una disminución progresiva y estable a lo largo de los pasos de entrenamiento, lo cual indica que el modelo aprendió de manera consistente sin señales de sobreajuste (overfitting). Con las configuraciones de LoRA ($r=16$, $\alpha=32$, $\text{dropout}=0.05$), la tasa de caída del loss es suave y converge adecuadamente alrededor del paso 120-180, donde ambos valores (entrenamiento y validación) se mantienen muy cercanos ($\sim 0.69-0.70$).




Figura 1. Evolución del Loss durante el Fine-Tuning de MedGemma con QLORA ($r=16$, $\alpha=32$, $\text{dropout}=0.05$)

Con las configuraciones de LoRA ($r = 16$, $\alpha = 32$, $\text{dropout} = 0.05$), la tasa de caída del *loss* es suave y converge adecuadamente alrededor del paso 120–180, donde ambos valores (entrenamiento y validación) se mantienen muy cercanos ($\approx 0.69 - 0.70$). Esta proximidad entre ambos sugiere que el modelo generaliza bien sobre el conjunto de validación y que el *fine-tuning* es estable, eficiente y sin divergencias.

La configuración LoRA ($r = 16$, $\alpha = 32$, $\text{dropout} = 0.05$) fue seleccionada por ofrecer el mejor equilibrio entre capacidad de adaptación, estabilidad y regularización. El valor $r = 16$ proporciona suficiente rango para aprender transformaciones estilísticas propias de los PLS sin sobreajustarse. El factor de escalado $\alpha = 32$ sigue la heurística $\alpha = 2r$ recomendada para maximizar la estabilidad del gradiente; y un *dropout* de 0.05 introduce regularización moderada que reduce alucinaciones y repeticiones sin afectar la coherencia semántica. Esta configuración mostró, tanto en literatura como en experimentación empírica, un comportamiento más estable y un mejor balance factualidad–legibilidad que opciones más agresivas ($r \geq 32$, $\alpha \geq 64$) o más restrictivas ($r \leq 8$).

G. Despliegue desarrollado: Como se resume en la Figura 2, el despliegue productivo alinea generación y verificación factual en una topología desacoplada: un EC2 t3.large con Docker Compose ejecuta un *front-end* Angular+nginx que consume */api* del *backend* en FastAPI. Este enruta la generación de PLS al *endpoint* de inferencia de Hugging Face y la validación factual a un microservicio *AlignScore* separado en */services/alignscore*, a fin de evitar incompatibilidades entre dependencias del proyecto principal.

Por otro lado, los *checkpoints* del clasificador y de *AlignScore* se almacenan en *buckets* S3 independientes. Las imágenes de los contenedores (*front/apilalignscore*) se publican en ECR y se provisionan de forma inmutable mediante *Makefile* y Terraform, lo que facilita la operación y reduce la deriva entre entornos, condición clave para sostener la calidad observada en los resultados.

Como se muestra en la Figura 3, se puede observar el *frontend* de acceso al sistema, diseñado con enfoque en usabilidad para el usuario final. La interfaz permite ejecutar la tarea de generación de PLS, incorporando una sección lateral con el historial de solicitudes y un panel central que posibilita la comparación entre el texto original y el PLS generado.

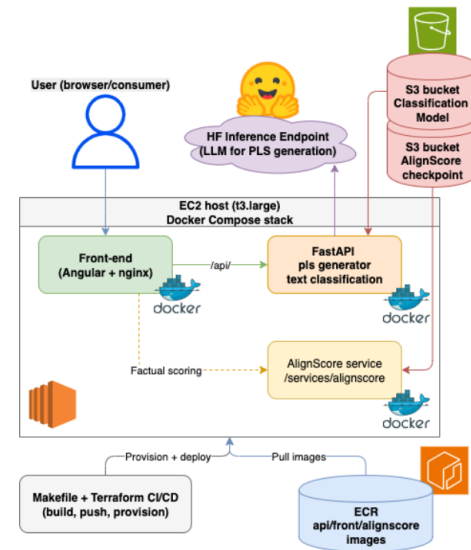


Figura 2. Arquitectura de despliegue realizada para el proyecto de generación PLS




Figura 3. Frontend del proyecto generación de PLS a textos biomédicos

Adicionalmente, en la parte inferior se incluye una sección de métricas que permite comprender de manera cuantitativa

el proceso de IA aplicado sobre el texto fuente, brindando trazabilidad y transparencia en la generación del resumen biomédico simplificado.

V. DISCUSIÓN Y APORTES

A. Modelos compactos como primera línea para PLS especializado.: Los ensayos con modelos compactos ($< 4B$) afinados con QLoRA aportan un hallazgo relevante para la comunidad: es posible abordar PLS biomédico con factualidad y relevancia competitivas sin acudir de entrada a modelos fundacionales costosos. Esta eficiencia parametrizable abre espacio para experimentación rigurosa (variar o suprimir instrucciones en el *prompt* y medir su efecto, datos y decodificación) con ciclos cortos y trazables, y reduce la barrera de entrada para hospitales y universidades con restricciones de presupuesto o cumplimiento. La principal limitación es que la legibilidad requiere todavía apoyos externos (*prompts* guiados, filtrado por clasificador y revisión humana).

B. Legibilidad sin perder factualidad: síntesis de evaluación cuantitativa y cualitativa.: Los resultados y su análisis confirman una tensión persistente entre factualidad y legibilidad en resúmenes biomédicos. Para proteger la fidelidad clínica, AlignScore exige conservar entidades, cifras y matices, lo que aumenta la longitud y la densidad terminológica. Al mismo tiempo, las métricas de legibilidad (Flesch–Kincaid, Gunning Fog, SMOG, Coleman–Liau) penalizan oraciones largas y vocabulario técnico. En el corpus usado, el número de caracteres de los textos técnicos ($P99 \approx 7,3k$ caracteres) y los PLS generados por expertos ($P99 \approx 5,5k$) evidencian que recortar agresivamente para “mejorar” legibilidad elimina contexto clínico y degrada AlignScore. Por lo tanto, la estrategia no es recortar el texto, sino reestructurar y explicar: segmentar ideas, definir términos, introducir ejemplos concretos y usar voz directa. Además, hace falta complementar las fórmulas clásicas con métricas centradas en comprensión y preservación de evidencia como la exactitud de entidades, relaciones PICO o pruebas de comprensión humana para no incentivar omisiones.

Es aquí donde la evaluación cualitativa aportó un contraste imprescindible cuando las métricas cuantitativas sugerían mensajes contradictorios. En varios lotes, BERTScore y AlignScore mostraron valores aceptables mientras las revisiones manuales detectaban omisiones críticas, jerga sin explicar o frases cortadas. Esa lectura manual permite ajustar el *prompt* (obligatoriedad de siete oraciones completas, idioma explícito, eliminación de encabezados), reforzar la compuerta del clasificador PLS/no-PLS y descartar salidas que pasaban las métricas automáticas, pero fallaban en claridad narrativa. Este diálogo entre métricas y juicio humano fue decisivo para calibrar los modelos y evitar decisiones guiadas únicamente por indicadores numéricos.

C. IA operable y escalable: arquitectura contenedorizada y despliegue en la nube.: Desde el inicio del proyecto se prioriza la viabilidad y factibilidad de llevar el modelo a producción, no solo su rendimiento desde una perspectiva

académica. El diseño contenedorizado (front Angular + nginx, API FastAPI y microservicio AlignScore) con imágenes publicadas en ECR y orquestación reproducible vía Terraform y Docker Compose permitió iterar rápidamente sobre *prompts* y *checkpoints* sin costos altos de mantenimiento, y escalar en una topología pequeña (t3.large) con rutas de artefactos de solo lectura. La API es altamente configurable, de modo que se puede conmutar proveedor o entorno sin reescribir la capa de presentación, algo que suele omitirse en ejercicios experimentales.

Por lo anterior, se puede afirmar que este proyecto estableció un punto de partida sólido en la puesta a producción de la solución: con documentación del ciclo MLOps completo, implementación de infraestructura como código con Terraform y uso de tecnología basada en la nube (AWS y Hugging Face) teniendo en cuenta la mejora continua de la mantenibilidad, favoreciendo la escalabilidad y la reducción de costos operativos.

VI. CONCLUSIONES Y TRABAJO FUTURO

- MedGemma fue el LLM que mejor controló la factualidad (AlignScore, contradicción y evaluación cualitativa superiores a Qwen). Llegó a superar los PLS humanos en legibilidad cualitativa (47 % vs. 0 %), pero no alcanzó la legibilidad cuantitativa objetivo de 8° ($0,49 < 0,8$). Dada la alta complejidad en los PLS de entrenamiento (FKGL $\sim 12^\circ$), MedGemma logra incluso obtener una legibilidad mayor (FKGL $\sim 11,22^\circ$).
- La evaluación cualitativa manual demostró ser imprescindible para la calibración del sistema, al detectar fallas narrativas críticas que las métricas automáticas pasaron por alto. Este análisis reveló que modelos comerciales de alto rendimiento como ChatGPT y Claude generaban resúmenes con un alarmante porcentaje de ideas incompletas – 52 % y 37 % respectivamente –, lo que reduce su factualidad y utilidad práctica en el ámbito médico. Esto se refuerza con la omisión de información relevante en un 26 % para ChatGPT y un 15 % para Claude.
- Lo anterior contrasta fuertemente con el comportamiento de los modelos ajustados. Por un lado, el modelo **Qwen** falló dramáticamente en las métricas cualitativas, presentando un 13 % de alucinaciones, un 90 % de omisiones de información crucial, un 40 % de errores gramaticales y un 61 % de jerga excesiva, haciéndolo inviable para un uso clínico seguro a pesar de su buen desempeño en métricas de fluidez como BERTScore. Por otro lado, **MedGemma** mostró un perfil mucho más robusto, con un 0 % de alucinaciones (igualando la referencia humana), un 0 % de errores gramaticales u ortográficos, y un nivel de omisiones (28 %) muy similar al de los resúmenes humanos (27 %).
- Así mismo, la gran diferencia entre los resultados cuantitativos y estos hallazgos cualitativos fue crucial para refinar la estrategia de generación, optando por una instrucción de *prompt* que exige un máximo de 500 palabras con ideas y frases completas. Este set de reglas garantiza la coherencia, el equilibrio entre resumen y

la preservación de conclusiones o hallazgos esenciales, reforzando una vez más, que el juicio humano es un componente imprescindible para el desarrollo de sistemas de IA fiables en el ámbito médico.

- Además, y teniendo en cuenta que la evaluación cualitativa y revisión manual mostraron textos que podrían llegar a cumplir con PLS de nivel 8°, se concluye que las métricas actuales para facticidad como AlignScore y QA-Answerability, así como las usadas para legibilidad (FKGL, FRE, GFog, SMOG, CLI) no son suficientes para medir de forma objetiva la generación automática de PLS ni la creación de los mismos por humanos, ya que por un lado, las métricas de legibilidad son fáciles de engañar con textos cortos y de baja calidad (frases cortadas), mientras que las de legibilidad son demasiado estrictas en su evaluación, haciendo que en ningún caso se clasifique un PLS como de grado 8vo o cercano a dicho nivel, aunque exista.
- Por otro lado, la incorporación de una línea MLOps completa (versionado de datos/modelos, contenedores reproducibles, IaC para infraestructura, CI/CD con pruebas y *smoke tests*, monitoreo/health checks y trazabilidad de artefactos) transforma el prototipo en un sistema operativo alineado con estándares industriales: asegura repetibilidad de resultados, gobernanza de dependencias y despliegues consistentes en la nube con costos controlados. Este enfoque es crucial para que las contribuciones académicas en PLS no se queden en el laboratorio, sino que puedan transferirse a entornos clínicos o productivos bajo prácticas de calidad y cumplimiento, elevando la credibilidad y el impacto real de la investigación ante una audiencia técnica exigente como lo es en este caso.

Asimismo, como trabajo futuro este proyecto quiere plantear lo siguiente:

- **Arquitectura de Aseguramiento de Calidad (Multi-Agente y Trazabilidad).** Para superar las limitaciones de un solo modelo generativo, se plantea la transición hacia un pipeline multi-agente inspirado en la metodología *Chain-of-Verification*:
 - **Descomposición Estructurada:** Implementación de un agente planificador que extraiga previamente la estructura PICO y las tablas numéricas del texto fuente.
 - **Verificación Determinística:** Integración de un módulo de “Guardas de Seguridad” (*Safety Guardrails*) que ejecute chequeos no neuronales (basados en reglas y Regex) antes de la entrega final. Esto incluye la normalización de unidades (mg/ μ g), la validación 1:1 de cifras críticas (dosis, intervalos de confianza) y la detección de poblaciones vulnerables (pediatría, embarazo).
 - **Salida Multimodal:** Generación dual que entregue el texto PLS junto con un Grafo de Conocimiento (KG) interactivo o *Study Card*, permitiendo la trazabilidad visual de la evidencia desde la afirmación simplificada hasta el fragmento original del texto técnico.

- **Desarrollo de la Métrica “Med-PLS Score”.** Se propone la estandarización de una métrica compuesta específica para biomedicina, diseñada para mitigar el sesgo de las métricas genéricas. La fórmula propuesta, *Med-PLS*, ponderará cinco dimensiones críticas:

- **Med-Align:** Facticidad semántica (NLI).
- **Med-Numbers:** Coincidencia exacta de cifras y unidades.
- **Med-Completeness:** Cobertura obligatoria de elementos de seguridad (contraindicaciones y efectos adversos).
- **Med-Risk:** Penalización por omisión de advertencias.
- **Readability Target:** Ajuste al nivel escolar objetivo.

Esta métrica se validará correlacionándola con un conjunto de datos anotado manualmente por un comité de expertos clínicos y comunicadores de salud.

- **Estrategias de Decodificación Restringida (*Constrained Decoding*).** Para resolver la “alucinación” de datos, se investigará el uso de técnicas de decodificación restringida durante la inferencia. Esto implica forzar al modelo a seleccionar tokens únicamente de un inventario de entidades extraídas del documento original (especialmente para nombres de fármacos y cifras), garantizando que el sistema no pueda generar información numéricamente inexistente en la fuente.
- **Equidad y Expansión al Español.** Más allá de los avances técnicos, la verdadera meta de este sistema es democratizar el acceso a la información médica. Sabemos que la barrera del idioma agrava las desigualdades en salud; de hecho, estudios fundamentales como el NAAL 2003 [?] han documentado que los adultos hispanohablantes enfrentan brechas significativas en su alfabetización en salud, lo que les dificulta tomar decisiones informadas sobre su bienestar. Por esta razón, el siguiente gran paso no es simplemente “traducir” el sistema, sino adaptarlo cultural y lingüísticamente. Esto implica curar nuevos conjuntos de datos nativos en español (pares técnico y PLS), ajustar las instrucciones (*prompts*) para que el tono sea cercano y natural, y, lo más importante, calibrar las métricas de evaluación para que juzguen la legibilidad según las reglas de nuestro idioma, garantizando así que la tecnología sirva como un puente real para la equidad.
- **MLOps, Observabilidad y Robustez Operativa.** De cara a robustecer el sistema, se debe implementar pruebas de carga con límites operativos estrictos y *dashboards* de observabilidad que monitoreen en tiempo real tanto el rendimiento de la infraestructura (latencias P50/P95 y uso de VRAM) como la calidad de la generación (promedio de AlignScore y tasa de rechazo del clasificador de estilo). Complementariamente, se deberán adoptar procedimientos de *Red-Teaming* clínico, diseñados para “atacar” sistemáticamente al modelo en puntos críticos como la interpretación de negaciones, la precisión de dosis y la identificación de poblaciones vulnerables. Este enfoque de vigilancia activa busca preservar el delicado

equilibrio entre el rigor técnico, el costo operativo y la utilidad clínica, asegurando que la futura expansión del sistema a entornos de recursos restringidos o su adaptación al español no comprometa en ningún momento la trazabilidad ni la factualidad de la información médica.

REFERENCIAS

- [1] N. D. Berkman, S. L. Sheridan, K. E. Donahue, D. J. Halpern, and K. Crotty, "Low health literacy and health outcomes: An updated systematic review," *Annals of Internal Medicine*, vol. 155, no. 2, pp. 97–107, 2011.
- [2] K. Sorensen, J. M. Pelikan, F. Röthlin, K. Ganahl, Z. Slonska, and G. Doyle, et al., "Health literacy in Europe: Comparative results of the European Health Literacy Survey (HLS-EU)," *European Journal of Public Health*, vol. 25, no. 6, pp. 1053–1058, 2015.
- [3] L. Bornmann and R. Mutz, "Growth rates of modern science: A bibliometric analysis based on the number of publications and cited references," *Journal of the Association for Information Science and Technology*, vol. 66, no. 11, pp. 2215–2222, 2015.
- [4] J. Hartley, "Health literacy, readability, and plain English," *European Journal of Communication*, vol. 31, no. 3, pp. 376–379, 2016.
- [5] M. Kutner, E. Greenberg, Y. Jin, and C. Paulsen, *The Health Literacy of America's Adults: Results From the 2003 National Assessment of Adult Literacy*. U.S. Department of Education, Institute of Education Sciences, 2006.
- [6] European Medicines Agency (EMA), *Guidance on plain language summaries of clinical trial results*, 2023. [Online]. Available: <https://www.ema.europa.eu/>
- [7] C. Glenton, B. Carlsen, S. Lewin, H. Munthe-Kaas, C. Colvin, and T. Tylleskär, "Barriers and facilitators to communicating evidence in plain language summaries in health," *BMC Medical Research Methodology*, vol. 19, no. 1, pp. 1–12, 2019.
- [8] A. Devaraj, A. Mishra, and J. J. Li, "NapSS: Paragraph-level Medical Text Simplification via Narrative Prompting and Sentence-matching Summarization," in *Findings of the Association for Computational Linguistics: EACL 2023*, 2023.
- [9] Z. Ji, N. Lee, R. Frieske, T. Yu, D. Su, and W. Shi, et al., "Survey of hallucination in natural language generation," *ACM Computing Surveys*, vol. 55, no. 12, pp. 1–38, 2023.
- [10] H. Nguyen and J. McCabe, "Medalyze: Evaluating the cost-performance trade-offs of commercial language models in clinical text generation," *Journal of Biomedical Informatics*, vol. 138, p. 104456, 2025.
- [11] L. Nielsen-Bohlman, A. M. Panzer, and D. A. Kindig, Eds., *Health literacy: A prescription to end confusion*. National Academies Press, 2004.
- [12] N. D. Berkman, S. L. Sheridan, K. E. Donahue, et al., "Health literacy interventions and outcomes: An updated systematic review," *Annals of Internal Medicine*, vol. 155, no. 2, pp. 97–107, 2011.
- [13] Referencia duplicada de Berkman (2011) en el PDF. Se omite para evitar redundancia.
- [14] T. A. Miller, "Health literacy and adherence to medical treatment in chronic and acute illness: A meta-analysis," *Patient Education and Counseling*, vol. 99, no. 7, pp. 1079–1086, 2016.
- [15] F. Arias-Russi, C. Salazar-Lara, and R. Manrique, "Bridging the Gap in Health Literacy: Harnessing the Power of Large Language Models to Generate Plain Language Summaries from Biomedical Texts," in *Proceedings of the 1st ClinicalNLP4Health Workshop*, Association for Computational Linguistics, 2025.
- [16] A. Devaraj, N. Rajani, and P. Liang, "Paragraph-level simplification of medical texts," in *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*, 2021.
- [17] Q. Xie, Y. Hu, J. Xu, et al., "A survey for biomedical text summarization: From pre-trained to large language models," *arXiv preprint arXiv:2304.08763*, 2023.
- [18] G. Adams, S. Zucker, and N. Elhadad, "Meta-evaluation of faithfulness metrics for long-form clinical summarization," *arXiv preprint arXiv:2303.03948*, 2023.
- [19] T. Zhang, V. Kishore, F. Wu, K. Q. Weinberger, and Y. Artzi, "BERTScore: Evaluating text generation with BERT," in *International Conference on Learning Representations (ICLR)*, 2020.
- [20] Y. Zha, Y. Yang, R. Li, and Z. Hu, "AlignScore: Evaluating Factual Consistency with a Unified Alignment Function," *arXiv preprint arXiv:2305.16739*, 2023.
- [21] Centers for Disease Control and Prevention, *Your Guide to CLEAR WRITING*, 2022.
- [22] R. Flesch, "A New Readability Yardstick," *Journal of Applied Psychology*, vol. 32, no. 3, pp. 221–233, 1948.
- [23] M. Coleman and T. L. Liao, "A Computer Readability Formula Designed for Machine Scoring," *Journal of Applied Psychology*, vol. 60, no. 2, pp. 283–284, 1975.
- [24] N. Joseph, J. Chen, Q. Jin, and W. Y. Wang, "FactPICO: Factuality evaluation for plain language summarization of medical evidence," *arXiv preprint arXiv:2402.11456*, 2024.
- [25] Z. Ji, S. Gao, Y. Li, and P. Fung, "RAG-RLRC-LaySum at Bio-LaySumm: Integrating retrieval-augmented generation and readability control for layman summarization of biomedical texts," *arXiv preprint arXiv:2405.13179*, 2024.
- [26] T. Nguyen, R. Patel, and C. Lee, "Medalyze: Lightweight medical report summarization application using FLAN-T5-Large," *arXiv preprint arXiv:2505.17059*, 2025.

ANEXO 1. PROMPT UTILIZADO PARA EL FINE-TUNING DE MODELOS COMPACTOS EN PYTHON

```
system_prompt = (
    "You are a Health Literacy Expert."
    "Your expertise is in rewriting complex,
    technical medical texts into clear, simple,
    and accurate language for a general
    audience, following established health
    communication guidelines.")
```

```
user_prompt = f"""**[PRIMARY GOAL]**
Your main purpose is to rewrite the
provided medical text into a Plain Language
Summary (PLS). This summary must be easy
to understand for someone with an 8th-grade
reading comprehension level typical of a
general middle-school student, consistent
with plain-language standards used by CDC
and NIH, meaning it should use simple
vocabulary, short sentences, and concepts
that can be understood by someone with
basic middle-school literacy, while
remaining completely faithful to the
source's essential information, for
instance, conclusions.
```

```
**[TASK INSTRUCTION]**
Rewrite the following technical medical
text into a Plain Language Summary (PLS).
The output MUST BE ONLY the plain
language summary without special symbols
and stop tokens.
```

```
**--- STRICT OUTPUT RULES ---**
```

```
1. **ACCURACY AND COMPLETENESS:**
* The summary MUST retain all key findings,
main outcomes, important safety
information, conclusions, and any
significant numerical results from the
original text.
* Do NOT add any information, opinions, or
recommendations that are not present in
the source document. The summary must be
based ONLY on the provided text.
```

```
2. **CLARITY AND READABILITY:**
* Write the summary at an **8th-grade
reading comprehension level typical of a
general middle-school student**.
* Use short, clear, and natural-sounding
sentences.
* Use the active voice whenever possible
(e.g., "Scientists tested the drug"
instead of "The drug was tested by
scientists").
* Avoid long, complex words when a simpler
alternative exists.
```

```
3. **TERMINOLOGY (JARGON):**
* Avoid medical jargon.
* If a technical term is absolutely
essential and cannot be replaced, you MUST
explain it simply in parentheses the first
time it appears. (Example: "The trial used
immunotherapy (a treatment that helps the
body's immune system fight cancer).")
```

```
4. **FORMATTING AND LANGUAGE:**
* The output MUST BE ONLY the plain
language summary without special symbols
and stop tokens, **only the summary**.
* The output must be written **ONLY in
English**.
* Structure the summary as a set of concise
paragraphs. Use as many sentences as needed
to include all essential information, up to
a maximum length of about 500 words, however,
**make sure ALL sentences are complete,
which means ALL ideas are finished.**
* Do NOT include headings, bullet points,
lists, citations, or URLs.
```

```
**--- SOURCE TECHNICAL TEXT ---**
<document>
{technical_text}
</document>
```

```
**--- PLAIN LANGUAGE SUMMARY (PLS)
"""
```